Mínimos cuadrados

Juan Fernando Paz

Interpolación

Supongamos que conocemos una función únicamente en algunos puntos:

$$(x_0, y_0),\ (x_1, y_1), \ldots, (x_n, y_n).$$

Interpolación

Supongamos que conocemos una función únicamente en algunos puntos:

$$(x_0, y_0),\ (x_1, y_1), \ldots, (x_n, y_n).$$

En interpolación polinómica buscamos un polinomio $p(x)$ que pase exactamente por todos los puntos:

$$\boxed{p(x_i) = y_i}$$

Datos experimentales

Supongamos que obtenemos datos mediante un experimento:

x	0	1	2	3	4
y	1,1	2,2	4,8	9,2	16,1

Es poco probable que los datos satisfagan exactamente una relación polinómica sencilla.

Datos experimentales

Supongamos que obtenemos datos mediante un experimento:

x	0	1	2	3	4
y	1,1	2,2	4,8	9,2	16,1

Es poco probable que los datos satisfagan exactamente una relación polinómica sencilla.

Pregunta

¿Queremos realmente que nuestro modelo pase exactamente por todos los datos?

Errores

Definimos el error en cada punto como

$$e_i = p(x_i) - y_i.$$

Ahora queremos que los errores sean, en conjunto, lo más pequeños posible.

Errores

Definimos el error en cada punto como

$$e_i = p(x_i) - y_i.$$

Ahora queremos que los errores sean, en conjunto, lo más pequeños posible.

Nueva pregunta

¿Cuál es el polinomio que mejor aproxima los datos?

El criterio de mínimos cuadrados

Mínimos cuadrados

Encontrar el modelo que minimiza la suma de los cuadrados de los errores.

$$E = \sum_{i=0}^{m-1} \left(p(x_i) - y_i\right)^2.$$

¿Qué estamos buscando?

Supongamos que queremos ajustar los datos mediante un polinomio de grado n:

$$p(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n.$$

Los parámetros desconocidos son

$$a_0, a_1, \ldots, a_n.$$

Por tanto, el problema consiste en encontrar estos coeficientes de manera que

$$\boxed{\sum_{i=0}^{m-1} \left(a_0 + a_1 x_i + \cdots + a_n x_i^n - y_i\right)^2}$$

sea mínima.

Ajuste lineal

Comencemos con una recta:

$$p(x) = a_0 + a_1 x.$$

Dados los datos

$$(x_0, y_0), \ldots, (x_{m-1}, y_{m-1}),$$

queremos encontrar a_0 y a_1 tales que

$$a_0 + a_1 x_i \approx y_i.$$

De un polinomio a un sistema lineal

Para el polinomio

$$p(x) = a_0 + a_1 x + \cdots + a_n x^n,$$

Podemos escribir todo como

$$\boxed{A\mathrm{a} \approx \mathrm{y}}$$

donde A es una matriz de Vandermonde.

Interpolación vs. mínimos cuadrados

La conexión aparece claramente al comparar los sistemas.

Interpolación

Con $n+1$ puntos:

$$A\mathrm{a} = \mathrm{y}.$$

La matriz A es cuadrada.

Buscamos:

$$\boxed{\text{error} = 0}$$

Mínimos cuadrados

Con $m > n+1$ datos:

$$A\mathrm{a} \approx \mathrm{y}.$$

La matriz A es rectangular.

Buscamos:

$$\boxed{\text{error mínimo}}$$

Interpretación geométrica

Queremos resolver

$$\min_{a} \|Aa - y\|_2.$$

Las columnas de A generan un subespacio:

$$\text{col}(A).$$

Todos los vectores Aa pertenecen a este subespacio.

Por tanto, buscamos el vector de $\text{col}(A)$ que esté más cerca de y.

Idea geométrica

El problema de mínimos cuadrados puede interpretarse como una **proyección ortogonal**.

La solución de mínimos cuadrados

El problema es

$$\boxed{\min_{\mathrm{a}} \|A\mathrm{a} - \mathrm{y}\|_2^2}$$

La solución a debe satisfacer las ecuaciones normales:

$$\boxed{A^T A\mathrm{a} = A^T \mathrm{y}}$$

Estas ecuaciones convierten el problema rectangular en un sistema cuadrado.

Pregunta

¿Cómo podemos resolver este sistema de manera eficiente y numéricamente confiable?

Ecuaciones normales

Las ecuaciones normales son

$$A^T A\mathrm{a} = A^T \mathrm{y}.$$

Podemos definir

$$B = A^T A, \qquad \mathrm{b} = A^T \mathrm{y}.$$

Entonces tenemos el sistema

$$\boxed{B\mathrm{a} = \mathrm{b}.}$$

Ahora aparece un problema familiar:

Resolver un sistema lineal.

Resolver mediante factorización LU

Si

$$A^T A = LU,$$

entonces las ecuaciones normales se convierten en

$$LU\mathrm{a} = A^T \mathrm{y}.$$

Introducimos un vector auxiliar z:

$$L\mathrm{z} = A^T \mathrm{y},$$

y posteriormente:

$$U\mathrm{a} = \mathrm{z}.$$

Ventaja

La factorización LU permite resolver el sistema mediante sistemas triangulares

¿Es siempre conveniente formar A^TA?

Las ecuaciones normales son sencillas:

$$A^TA\mathrm{a} = A^T\mathrm{y}.$$

Pero formar A^TA puede ser problemático desde el punto de vista numérico.
Una de las razones es que, en términos del número de condición,

$$\boxed{\kappa(A^TA) \approx \kappa(A)^2.}$$

Es decir, el condicionamiento puede empeorar considerablemente.

Pregunta

¿Podemos resolver directamente $A\mathrm{a} \approx \mathrm{y}$ sin formar A^TA?

Factorización QR

Una matriz A puede factorizarse como

$$\boxed{A = QR}$$

donde:

- Q tiene columnas ortonormales.
- R es triangular superior.

La factorización QR está estrechamente relacionada con la proyección ortogonal.

Mínimos cuadrados mediante QR

Partimos de

$$A\mathrm{a} \approx \mathrm{y}.$$

Usando

$$A = QR,$$

obtenemos

$$QR\mathrm{a} \approx \mathrm{y}.$$

La solución de mínimos cuadrados se obtiene resolviendo

$$\boxed{R\mathrm{a} = Q^T\mathrm{y}.}$$

Por tanto:

¿Por qué aparece QR?

Recordemos la interpretación geométrica:

$$Aa$$

debe ser la proyección de y sobre

$$\text{col}(A).$$

Las columnas de Q forman una base ortonormal de este espacio.

Por tanto, Q nos permite representar la proyección de manera estable y eficiente.

Idea clave

La factorización QR transforma el problema de mínimos cuadrados en un problema triangular.

Ecuaciones normales vs. QR

	Ecuaciones normales	**QR**
Problema	$A^T A\mathrm{a} = A^T \mathrm{y}$	$R\mathrm{a} = Q^T \mathrm{y}$
Forma $A^T A$	Sí	No
Condicionamiento	Puede empeorar	Más favorable
Costo	Menor	Mayor
Uso	Problemas sencillos	Cálculo numérico confiable

Mensaje

La elección del método importa cuando trabajamos con problemas numéricamente sensibles.

Ejemplo: ajustar una recta

Consideremos los datos

$$(0,1), \quad (1,2), \quad (2,5), \quad (3,10), \quad (4,17).$$

Queremos aproximarlos mediante

$$p(x) = a_0 + a_1 x.$$

Entonces

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix}, \qquad \mathrm{y} = \begin{bmatrix} 1 \\ 2 \\ 5 \\ 10 \\ 17 \end{bmatrix}.$$

Nuestro problema es

Ejemplo: ecuaciones normales

Para el ejemplo anterior:

$$A^T A = \begin{bmatrix} 5 & 10 \\ 10 & 30 \end{bmatrix}$$

y

$$A^T \mathrm{y} = \begin{bmatrix} 35 \\ 100 \end{bmatrix}.$$

Por tanto:

$$\boxed{\begin{bmatrix} 5 & 10 \\ 10 & 30 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 35 \\ 100 \end{bmatrix}}$$

Para desarrollar en el tablero

Resolver el sistema y obtener la recta de mínimos cuadrados.

Ejemplo: comparar con interpolación

Los mismos datos también pueden interpolarse mediante un polinomio de grado 4.
De hecho,

$$y = x^2 + 1.$$

Por tanto, la interpolación produce

$$\boxed{p_{\text{interp}}(x) = x^2 + 1.}$$

Pero si restringimos nuestro modelo a una recta, mínimos cuadrados produce una aproximación diferente:

$$\boxed{p_{\text{MC}}(x) = a_0 + a_1 x.}$$

Pregunta

¿Qué información estamos priorizando en cada caso?

Interpolación vs. mínimos cuadrados

	Interpolación	**Mínimos cuadrados**
Objetivo	Pasar exactamente por los datos	Aproximar los datos
Error	$p(x_i) - y_i = 0$	Error global mínimo
Datos	Generalmente $n + 1$	Puede haber muchos más datos
Grado	Determinado por los datos	Elegido según el modelo
Sistema	$A\mathrm{a} = \mathrm{y}$	$A\mathrm{a} \approx \mathrm{y}$
Aplicación	Interpolación	Ajuste de modelos

Una diferencia importante

En interpolación:

$$\boxed{\text{más puntos} \quad \Rightarrow \quad \text{mayor grado}}$$

si queremos interpolar todos los puntos con un único polinomio.

En mínimos cuadrados podemos mantener fijo el grado:

$$\boxed{\text{más puntos} \quad \not\Rightarrow \quad \text{mayor grado}}$$

Por ejemplo, podemos ajustar:

$$p(x) = a_0 + a_1 x$$

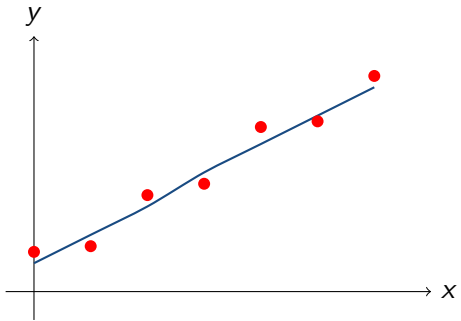
utilizando

$$10, \quad 100, \quad 1000$$

o muchos más datos

¿Qué ocurre con datos ruidosos?

Supongamos que los datos provienen de un experimento.



Idea

Los datos pueden contener errores de medición.
En este contexto, exigir que el modelo pase exactamente por cada punto puede no ser el objetivo adecuado.

Interpolación y extrapolación

La interpolación busca estimar valores dentro del intervalo de los datos:

$$x \in [x_0, x_n].$$

La extrapolación intenta estimar valores fuera de ese intervalo:

$$x < x_0 \qquad \text{o} \qquad x > x_n.$$

Advertencia

Un polinomio que reproduce muy bien los datos dentro del intervalo puede tener un comportamiento poco razonable fuera de él.

El grado del polinomio

En interpolación, al aumentar el número de puntos podemos terminar con polinomios de grado elevado.
Esto puede producir:

- oscilaciones,
- sensibilidad numérica,
- comportamiento inesperado fuera del intervalo,
- matrices de Vandermonde mal condicionadas.

En mínimos cuadrados podemos escoger un modelo de grado menor:

$$p(x) = a_0 + a_1 x + \cdots + a_n x^n$$

aunque tengamos muchos datos.

Ejercicio 1 — Ajuste lineal

Considere los datos

x	0	1	2	3	4	5
y	1,2	2,1	2,9	4,2	4,8	6,1

Ajuste una recta

$$p(x) = a_0 + a_1 x$$

mediante mínimos cuadrados.

- Construya la matriz A.
- Construya $A^T A$ y $A^T y$.
- Resuelva las ecuaciones normales.
- Grafique los datos y la recta obtenida.

Ejercicio 2 — Ajuste polinómico

Considere los datos

x	0	1	2	3	4	5	6	7
y	1,1	1,9	4,2	8,8	16,2	25,1	36,8	48,9

Ajuste polinomios de grados

$$1, \qquad 2, \qquad 3.$$

Para cada caso:

- Construya la matriz A.
- Calcule el ajuste mediante mínimos cuadrados.
- Grafique los datos y el polinomio.
- Compare los errores.

Ejercicio 3 — Ecuaciones normales vs. QR

Utilice los datos del ejercicio anterior.
Para el polinomio de grado 3:

$$p(x) = a_0 + a_1 x + a_2 x^2 + a_3 x^3.$$

Calcule los coeficientes utilizando:

1. Ecuaciones normales.
2. Factorización QR.

Compare los resultados obtenidos.

Pregunta

¿Los coeficientes obtenidos son exactamente iguales?