Valores propios

Juan Fernando Paz

Motivación

Pregunta

¿Existen direcciones que una transformación lineal no cambia, excepto por un factor de escala?

Es decir,

$$\boxed{Av = \lambda v}$$

donde

$$v \neq 0.$$

- v: vector propio.
- λ: valor propio.

Esto ocurre si y solamente si

$$\boxed{\det(A - \lambda I) = 0.}$$

Definimos el polinomio característico

$$p_A(\lambda) = \det(A - \lambda I).$$

Definición

Los valores propios de A son las raíces del polinomio característico.

Ejemplo: matriz diagonal

Consideremos

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}.$$

Entonces

$$\det(A - \lambda I) = \begin{vmatrix} 3-\lambda & 0 \\ 0 & 2-\lambda \end{vmatrix}.$$

Por tanto,

$$(3-\lambda)(2-\lambda) = 0.$$

Los valores propios son

$$\boxed{\lambda_1 = 3, \qquad \lambda_2 = 2.}$$

Los vectores propios correspondientes son

$$v_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \qquad v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Un valor propio λ

Para encontrar los vectores propios asociados a λ resolvemos

$$(A - \lambda I)v = 0.$$

Un valor propio λ

Para encontrar los vectores propios asociados a λ resolvemos

$$(A - \lambda I)v = 0.$$

Aquellos $\{v_1, v_2, \ldots, v_k\}$ que satisfacen $(A - \lambda I)v_i = 0$, son los valores propios asociados a λ.

El espacio generado por $\{v_1, v_2, \ldots, v_k\}$ se conoce como **espacio propio** asociado a λ y tiene dimensión k.

Multiplicidad algebraica

Multiplicidad algebraica

La multiplicidad algebraica $m_a(\lambda)$ es el número de veces que λ aparece como raíz de p_A.

Por ejemplo,

$$p_A(\lambda) = (\lambda - 2)^3(\lambda + 1)^2.$$

Entonces

$$m_a(2) = 3, \qquad m_a(-1) = 2.$$

Multiplicidad geométrica

Multiplicidad geométrica

La multiplicidad geométrica de λ es la dimensión del **espacio propio** asociado a λ.

Multiplicidad geométrica

La multiplicidad geométrica de λ es la dimensión del **espacio propio** asociado a λ.

Siempre se cumple

$$\boxed{1 \leq m_g(\lambda) \leq m_a(\lambda).}$$

Ejemplo: multiplicidades iguales

Consideremos

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}.$$

Ejemplo: multiplicidades iguales

Consideremos

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}.$$

Tenemos $m_a(2) = 1$ y $m_g(2) = 1$, y $m_a(3) = 1$, $m_g(3) = 1$.

Ejemplo: multiplicidades diferentes

Consideremos

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}.$$

Ejemplo: multiplicidades diferentes

Consideremos

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}.$$

Tenemos $m_a(2) = 2$ y $m_g(2) = 1$, $m_g(2) < m_a(2)$.

¿Cuándo es diagonalizable una matriz?

Una matriz $A \in \mathbb{R}^{n \times n}$ es diagonalizable si existe una matriz invertible V tal que

$$\boxed{A = V \Lambda V^{-1}}$$

donde Λ es diagonal.
Equivalentemente:

Criterio de diagonalización

A es diagonalizable si y solamente si posee n vectores propios linealmente independientes.

En términos de multiplicidades:

$$\boxed{m_g(\lambda) = m_a(\lambda) \quad \text{para todo } \lambda.}$$

¿Por qué es útil diagonalizar?

Si

$$A = V\Lambda V^{-1},$$

entonces

$$A^k = V\Lambda^k V^{-1}.$$

¿Por qué es útil diagonalizar?

Si

$$A = V\Lambda V^{-1},$$

entonces

$$A^k = V\Lambda^k V^{-1}.$$

Idea

El comportamiento de A^k está determinado por las potencias λ_i^k.

¿Qué ocurre si A no es diagonalizable?

Si

$$m_g(\lambda) < m_a(\lambda),$$

no existen suficientes vectores propios para formar una base.
Pero podemos buscar vectores v que satisfagan

$$(A - \lambda I)^k v = 0$$

para algún $k > 1$.

Vector propio generalizado

Un vector $v \neq 0$ es un vector propio generalizado asociado a λ si existe $k \geq 1$ tal que

$$(A - \lambda I)^k v = 0.$$

Ejemplo de vector propio generalizado

Consideremos nuevamente

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}.$$

Tenemos

$$v_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

como vector propio.
Buscamos v_2 tal que

$$(A - 2I)v_2 = v_1.$$

Tomando

$$v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix},$$

obtenemos

$$(A - 2I)v_2 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = v_1.$$

Así,

$$\{v_1, v_2\}$$

forma una base de $\mathbb{R}^2$.

Forma de Jordan

Los vectores propios generalizados permiten construir una base en la cual

$$A = VJV^{-1},$$

donde J es la forma de Jordan.
Un bloque de Jordan tiene la forma

$$J = \begin{pmatrix} \lambda & 1 & 0 & \cdots \\ 0 & \lambda & 1 & \cdots \\ 0 & 0 & \lambda & \cdots \\ \vdots & & & \ddots \end{pmatrix}.$$

Mensaje principal

Aunque una matriz no sea diagonalizable, los vectores propios generalizados permiten construir una base sobre $\mathbb{C}^n$.

Método de las potencias

Supongamos que A es diagonalizable:

$$A = V\Lambda V^{-1}.$$

Escribimos un vector inicial como combinación de vectores propios:

$$x_0 = c_1 v_1 + \cdots + c_n v_n.$$

Entonces

$$A^k x_0 = c_1 \lambda_1^k v_1 + \cdots + c_n \lambda_n^k v_n.$$

Con

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|.$$

Entonces

$$A^k x_0 \approx c_1 \lambda_1^k v_1.$$

Método de las potencias: idea

La iteración básica es

$$x_{k+1} = Ax_k.$$

Para evitar que el vector crezca o disminuya demasiado, normalizamos:

$$\boxed{x_{k+1} = \frac{Ax_k}{\|Ax_k\|}.}$$

Bajo condiciones apropiadas,

$$x_k \longrightarrow \frac{v_1}{\|v_1\|}.$$

El método permite aproximar el eigenvector asociado al eigenvalor dominante.

Estimación del valor propio

Una vez obtenido un vector x_k cercano al vector propio, podemos utilizar el cociente de Rayleigh:

$$\boxed{\lambda_k = \frac{x_k^T A x_k}{x_k^T x_k}.}$$

Si

$$Ax = \lambda x,$$

entonces

$$\frac{x^T A x}{x^T x} = \frac{x^T (\lambda x)}{x^T x} = \lambda.$$

Por tanto, el cociente de Rayleigh recupera exactamente el valor propio para un vector propio.

Velocidad de convergencia

Para el método de las potencias, supongamos

$$|\lambda_1| > |\lambda_2|.$$

Entonces el término dominante es λ_1^k.
Los términos restantes están controlados por

$$\left|\frac{\lambda_i}{\lambda_1}\right|^k.$$

En particular, la velocidad está relacionada con

$$\boxed{\left|\frac{\lambda_2}{\lambda_1}\right|}.$$

Si

$$\left|\frac{\lambda_2}{\lambda_1}\right| \approx 1,$$

la convergencia puede ser muy lenta.

Radio espectral

Definición

El radio espectral de una matriz A es

$$\boxed{\rho(A) = \max_i |\lambda_i|.}$$

Es decir, es el módulo del valor propio de mayor magnitud.

Si

$$\lambda_1, \ldots, \lambda_n$$

son los valores propios,

$$\rho(A) = \max\{|\lambda_1|, \ldots, |\lambda_n|\}.$$

Radio espectral y normas

Para toda norma matricial subordinada,

$$\boxed{\rho(A) \leq \|A\|.}$$

Por tanto,

$$\|A\| < 1 \quad \Longrightarrow \quad \rho(A) < 1.$$

También

$$\rho(A) > 1 \quad \Longrightarrow \quad \|A\| > 1.$$

Ejemplo: $\rho(A)$ no determina $\|A\|$

Consideremos

$$A = \begin{pmatrix} 1 & 100 \\ 0 & 1 \end{pmatrix}.$$

Sus valores propios son

$$\lambda_1 = \lambda_2 = 1.$$

Por tanto,

$$\boxed{\rho(A) = 1.}$$

Sin embargo, la norma puede ser mucho mayor que 1.

Mensaje

El radio espectral mide el crecimiento asintótico asociado a los valores propios, mientras que una norma también puede capturar efectos transitorios.

Propagación de errores

Supongamos una iteración

$$x_{k+1} = Tx_k + c.$$

Sea x^* el punto fijo:

$$x^* = Tx^* + c.$$

Definimos el error

$$e_k = x_k - x^*.$$

Entonces

$$e_{k+1} = Te_k.$$

Por inducción,

$$\boxed{e_k = T^k e_0.}$$

¿Cuándo desaparece el error?

Tenemos

$$e_k = T^k e_0.$$

Por tanto,

$$\|e_k\| \leq \left\| T^k \right\| \|e_0\|.$$

Si existe una norma tal que

$$\|T\| < 1,$$

entonces

$$\|e_k\| \leq \|T\|^k \|e_0\| \longrightarrow 0.$$

Una condición fundamental más general es

$$\boxed{\rho(T) < 1.}$$

Jacobi y valores propios

Recordemos el método de Jacobi:

$$x^{(k+1)} = T_J x^{(k)} + c.$$

El error satisface

$$e^{(k+1)} = T_J e^{(k)}.$$

Por tanto,

$$e^{(k)} = T_J^k e^{(0)}.$$

La convergencia está determinada por el radio espectral:

$$\boxed{\rho(T_J) < 1 \quad \Longrightarrow \quad x^{(k)} \to x^*.}$$

Importante

La condición involucra la matriz de iteración T_J, no necesariamente la matriz original A.

Condición suficiente mediante una norma

Como

$$\rho(T_J) \leq \|T_J\|,$$

tenemos

$$\boxed{\|T_J\| < 1 \quad \Longrightarrow \quad \rho(T_J) < 1.}$$

Por tanto,

$$\|T_J\| < 1$$

es una condición suficiente para la convergencia de Jacobi.
Pero:

$$\rho(T_J) < 1$$

es la condición fundamental.

La idea general

Muchos métodos iterativos pueden escribirse como

$$x_{k+1} = Tx_k + c.$$

Entonces

$$e_k = T^k e_0.$$

La pregunta fundamental es:

$$\text{¿Qué ocurre con } T^k \text{ cuando } k \to \infty?$$

La respuesta está relacionada con

$$\boxed{\rho(T).}$$

$$\rho(T) < 1 \quad \Longrightarrow \quad T^k \to 0.$$

Métodos y problemas que resuelven

Método	**Problema**	**Idea principal**
LU	$Ax = b$	Factorización $A = LU$
QR	$Ax = b$ / valores propios	Factorización ortogonal
Jacobi	$Ax = b$	Iteración $x_{k+1} = Tx_k + c$
Potencias	Valor propio dominante	Iterar $x_{k+1} = Ax_k$
Potencia inversa	Valor propio cercano a μ	Aplicar potencias a $(A - \mu I)^{-1}$
QR iterativo	Todos los valores propios	$A_k = Q_k R_k$, $A_{k+1} = R_k Q_k$

Ecuaciones normales

En mínimos cuadrados resolvemos

$$\min_x \|Ax - b\|_2 .$$

Las ecuaciones normales son

$$\boxed{A^T Ax = A^T b.}$$

Aparece naturalmente la matriz

$$A^T A.$$

Esta matriz es simétrica:

$$(A^T A)^T = A^T A.$$

Además,

$$x^T A^T A x = \|Ax\|_2^2 \geq 0.$$

Por tanto, $A^T A$ es semidefinida positiva.

Valores propios de $A^T A$

Si

$$A^T A v = \lambda v,$$

multiplicamos por v^T:

$$v^T A^T A v = \lambda v^T v.$$

Pero

$$v^T A^T A v = \|Av\|_2^2 .$$

Por tanto,

$$\boxed{\lambda = \frac{\|Av\|_2^2}{\|v\|_2^2} \geq 0.}$$

Los valores propios de $A^T A$ son siempre no negativos.

Condicionamiento de las ecuaciones normales

Si A tiene rango completo,

$$\kappa_2(A^T A) = \frac{\lambda_{\text{máx}}(A^T A)}{\lambda_{\text{mín}}(A^T A)}.$$

Además, los valores propios de $A^T A$ son cuadrados de cantidades asociadas a A.
Esto lleva a

$$\boxed{\kappa_2(A^T A) = \kappa_2(A)^2.}$$

Consecuencia numérica

Las ecuaciones normales pueden amplificar los problemas de condicionamiento.